

ĐỀ TÀI P-132 · ORBIT AI ASSISTANT

Xây dựng trợ lý AI cá nhân **thông minh, chủ động và đáng tin cậy.**

Orbit Personal Agent ứng dụng LLM và kiến trúc agentic để thấu hiểu nhu cầu, tổ chức công việc, ghi nhớ điều quan trọng và hỗ trợ người dùng đúng lúc — minh bạch, an toàn và luôn dưới quyền quyết định của họ.

LLM-powered

Agentic workflow

Human-in-the-loop

Privacy & consent

BỐI CẢNH ĐỀ TÀI

Thông tin cá nhân nằm rải rác; hành động vẫn phải nổi thủ công.

Một quyết định có thể xuất hiện trong chat, deadline nằm trong task, cuộc họp ở Calendar và cách làm việc nằm trong memory. Đề tài giải quyết khoảng trống giữa “biết thông tin” và “thực hiện bước tiếp theo”.

MỤC TIÊU ĐỀ TÀI

Xây dựng một agent biết hiểu, ghi nhớ, lập kế hoạch và sử dụng công cụ — nhưng không vượt quyền.

01

Hiểu ngữ cảnh

Tóm tắt hội thoại, tìm thông tin và phát hiện cam kết từ dữ liệu được cấp quyền.

02

Tổ chức công việc

Trích xuất task, ưu tiên deadline và hợp nhất dữ liệu thành timeline cá nhân.

03

Hành động có kiểm soát

Tạo draft lịch hoặc reminder, dừng bằng interrupt và chỉ thực thi sau xác nhận.

04

Duy trì niềm tin

Áp dụng owner filter, consent, guardrail, provenance và trạng thái bền vững.

ĐÓNG GÓP HIỆN THỰC HÓA

Đề tài đã hình thành một nền tảng agentic end-to-end có thể trình diễn và kiểm chứng.

14

tool nghiệp vụ cho chat, task, Calendar, reminder và context

3

nhà cung cấp LLM có thể cấu hình qua một model factory

HITL

interrupt/resume kiểm soát side effect trước thực thi

435

test backend passed trong lần chạy xác nhận

Giao diện, API, LangGraph, tool execution, PostgreSQL persistence, scheduler và realtime đã được nối thành luồng chạy thật — tạo nền tảng rõ ràng cho demo và tiếp tục hardening.

TÍN HIỆU BỊ CHÔN VÙI

Công việc quan trọng đang nằm rải rác trong quá nhiều bề mặt.

Deadline có thể ở chat, cuộc họp nằm trong Calendar, còn cách làm việc lại nằm trong trí nhớ của chính người dùng.

01

CHI PHÍ THỰC

Bỏ lỡ không chỉ là quên — đó là mất niềm tin.

1

Chi phí chú ý

Đọc lại, tìm kiếm và đối chiếu nhiều nguồn.

2

Chi phí phối hợp

Cam kết thiếu owner, hạn hoặc nguồn.

Bài toán đúng không phải “trả lời hay hơn”, mà là “chuyển ngữ cảnh thành bước tiếp theo có thể kiểm soát”.

NGƯỜI DÙNG MỤC TIÊU

Người làm việc tri thức với lịch và hội thoại **dày đặc**.

Họ diễn đạt bằng ngôn ngữ tự nhiên và duyệt hành động trước khi hệ thống thực thi.

NGUYÊN TẮC

Giá trị phải đi cùng quyền kiểm soát.

Private by default

Dữ liệu lọc theo người dùng đã xác thực.

Consent before context

Chỉ nội dung được phép mới tới mô hình.

Propose before execute

Side effect phải dừng để xác nhận.

Evidence over claims

Tuyên bố phải truy được về code hoặc test.

RANH GIỚI SẢN PHẨM

Orbit không phải chatbot **kiến thức tổng quát.**

Domain giới hạn ở năng suất công việc, task, lịch, reminder, memory, giao tiếp chuyên nghiệp và phân tích chat được cấp quyền.

CAPABILITY MAP

Năm cụm năng lực tạo nên Personal Agent.

Converse

Chat riêng, thread, lịch sử.

Understand

Tóm tắt, search, trích xuất task.

Organize

Task, priority inbox, timeline.

Act

Calendar, reminder, conflict.

Remember

Memory có loại, hạn và provenance.

Protect

Auth, consent, guardrail, HITL, budget.

MÀN HÌNH TRỢ LÝ

Ba vùng: phiên gần đây, hội thoại, bối cảnh hôm nay.



Phiên gần đây

Tìm, mở lại hoặc bắt đầu phiên mới.



Personal AI Chat

Nhập tự nhiên, Markdown và confirmation.

THREAD HISTORY

Mỗi người chỉ thấy các phiên trợ lý của chính mình.

- ✓ Tối đa 50 phiên, mới nhất ở trên.
- ✓ Tiêu đề tối đa 60 ký tự.
- ✓ Preview tối đa 80 ký tự.
- ✓ Chỉ phát lại lượt user/assistant có nội dung.

AI TRONG CHAT

Trợ lý xuất hiện ngay tại cuộc trò chuyện đang đọc.

Panel riêng cung cấp quick actions và Ask Orbit, giữ conversation identity để backend kiểm tra quyền.

QUYỀN AI

Quyền đọc chat và quyền cho AI xử lý là hai việc khác nhau.

01

Participant

Phải có quyền đọc chat.

02

AI enabled

Quyền trợ lý được bật.

03

Contribution

Tác giả đủ điều kiện.

SCOPE SELECTOR

Người dùng chọn cửa sổ dữ liệu thay vì gửi toàn bộ lịch sử.

Latest

20 hoặc 50 tin gần nhất.

Activity

Unread, hôm nay, hôm qua, tuần này.

Rolling

Một hoặc năm giờ gần nhất.

Custom

Từ thời điểm A đến B.

latest_n tối đa 50; các range dài query tối đa 500 message ở server.

TÓM TẮT

Tóm tắt là tool chuyên biệt, không để planner tự ứng tác.

- ✓ Ba style: brief, detailed, bullet points.
- ✓ Luôn trả tiếng Việt.
- ✓ Dữ liệu được bọc là untrusted.
- ✓ Ngày tương đối neo theo múi giờ.
- ✓ Không có lượt LLM relay thứ hai.

TASK EXTRACTION

Kết quả trích xuất bị ép vào **schema rõ ràng**.

Tool yêu cầu JSON array và xác thực bằng Pydantic; output sai trở thành mảng rỗng.

AI SUGGESTIONS

Task trích xuất chưa tự trở thành cam kết đã chấp nhận.

01

Extract

Tool trả candidate.

02

Validate

Kiểm tra source.

03

Suggested

Lưu chờ duyệt.

PROACTIVE AGENT

Orbit có thể phát hiện cam kết **ngay khi chat phát sinh.**

Luồng nền không chặn gửi message: lọc liên quan → phân tích cửa sổ → xác minh owner → tạo suggestion → realtime.

PRIORITY INBOX

Một inbox gom đúng những gì cần quyết định trước.

AI

candidate chờ Accept/Dismiss

Late

task đã quá hạn

48h

task đến hạn trong hai ngày

High

ưu tiên cao còn lại

TASK LIFECYCLE

Task có vòng đời đủ để theo dõi, từ gợi ý đến invalidated.

TRẠNG THÁI	Ý NGHĨA	QUY TẮC
suggested	AI đề xuất	Re-check provenance khi Accept
pending / in_progress	Đang xử lý	Cập nhật realtime
blocked	Bị cản trở	Bắt buộc blocked_reason
completed / dismissed	Đã kết thúc	Không nằm trong task mở
invalidated	Nguồn AI mất hợp lệ	Phải extract lại

GOOGLE CALENDAR

Mỗi người kết nối Calendar của **chính mình.**

- ✓ Authorization code đổi credential ở backend.
- ✓ Refresh/access token được mã hóa.
- ✓ OAuth state gắn user và có expiry.
- ✓ Disconnect revoke rồi xóa credential.

CREATE EVENT

Agent chỉ tạo draft; side effect xảy ra sau confirmation.

01

Intent

Yêu cầu đặt lịch.

02

Draft

Title, start, end.

03

Verify

Policy và conflict.

CONFLICT HANDLING

Khi trùng lịch, Orbit đưa xung đột và tối đa **hai phương án thay thế.**

Người dùng chọn slot khác, giữ giờ cũ hoặc hủy — hệ thống không quyết định thay.

REMINDER

Reminder có due time, lead time và thời điểm fire riêng.

Deadline 17:00 với lead 30 phút tạo fire_at lúc 16:30. Due và fire đều phải ở tương lai.

REMINDER RELIABILITY

Job nhắc việc sống qua restart và bắn **realtime** khi đến giờ.

- ✓ APScheduler dùng SQLAlchemyJobStore.
- ✓ Job và reminder lưu bền vững.
- ✓ Fire đổi status rồi broadcast.
- ✓ Cancel gỡ job nếu còn scheduled.

MEMORY UI

Người dùng có quyền thêm, sửa, tìm và xóa điều Orbit ghi nhớ.

Add

Tạo title, category, detail.

Search

Lọc nội dung và category.

Edit

Cập nhật bản ghi của mình.

Delete

Xóa vĩnh viễn qua API.

UI nói rõ người dùng kiểm soát điều gì được nhớ.

MEMORY MODEL

Bốn loại memory, có confidence và ngày hết hạn.

LOẠI	VÍ DỤ	VAI TRÒ
preference	Ưu tiên báo cáo dạng bullet.	Cá nhân hóa phản hồi
relationship	Lan là đầu mối backend.	Hiểu người liên quan
episodic	Tuần trước đã chốt review.	Nhớ sự kiện
semantic	Dự án dùng mã BLUE-42.	Nhớ tri thức công việc

- confidence 0..1
- expires_at
- last_accessed_at
- normal / sensitive

MEMORY SAFETY

Memory không được biến thành kho chứa **secret thứ hai**.

Create và update từ chối credential hoặc dữ liệu cá nhân nhạy cảm bằng rule deterministic.

PERSONAL TIMELINE

Một timeline hợp nhất task, reminder, Calendar và chat được phép.

Range tối đa 90 ngày; message cần conversation cụ thể và quyền truy cập hợp lệ.

DEMO 01

Bạn

Tổng hợp lịch, task và deadline của tôi hôm nay.

Orbit

Gọi timeline/task/calendar read tools; sắp theo thời gian và chú ý.

DEMO 03

Lan · 10:12

Chiều mai mình gửi bản API review trước 16h.

Orbit candidate

Gửi bản API review · 16:00 ngày mai · High

Bạn
Accept

DEMO 04

Từ deadline thành reminder, nhưng đừng trước khi tạo.

Bạn

Nhắc tôi gửi báo cáo lúc 16:30 ngày mai.

Orbit • Pending confirmation

Tạo nhắc nhở “Gửi báo cáo” lúc 16:30 ngày mai?

Bạn

Xác nhận

Orbit

Đã tạo nhắc nhở “Gửi báo cáo”.

DEMO 05

Propose & Verify thay vì âm thầm double-book.

Orbit kiểm tra conflict trước interrupt, đính kèm lịch trùng và hai slot thay thế nếu có.

SYSTEM VIEW

Frontend → API → LangGraph → tools → dịch vụ dữ liệu.

REACT	Chat, tasks, calendar, reminders, memory	UI
FASTAPI	JWT, validation, ownership, consent	API
LANGGRAPH	Guardrail, planner, tools, compaction	Agent
SERVICES	PostgreSQL, Google, scheduler, WebSocket	Runtime
LLM	Google, Groq hoặc OpenAI	Model

Năm node tạo thành vòng đời một turn.

01

Input guardrail

Block hoặc clarify.

02

Planner

Trả lời hoặc chọn tool.

03

ToolNode

Thực thi tool bind sẵn.

Summary/task extraction đi thẳng END để tránh LLM relay lần hai; đây là ngoại lệ có chủ đích.

PLANNER

LLM là bộ lập kế hoạch, không phải nguồn quyền.

System prompt

Domain, tool rules, tiếng Việt, ngày tương đối, untrusted data.

Dynamic context

Tối đa 5 people context và 5 memory.

Identity, consent và access được kiểm tra ngoài prompt; prompt không phải security boundary.

TOOL CATALOG

14 tool của Personal Agent.

Chat • 3

summarize_conversation
extract_tasks
search_messages

Calendar • 4

create
list
update
delete event

Reminder • 2

create_reminder
list_reminders

Context • 5

tasks, memories, people, timeline, policy

TOOL POLICY

Đọc và ghi có mức rủi ro khác nhau.

NHÓM	VÍ DỤ	CONFIRMATION	KIỂM SOÁT
Read-only	task, lịch, memory	Không	Owner + data scope
Analysis	summary, extract	Không	Authorized context + schema
State-changing	Calendar create/update/delete	Có	Policy → interrupt → recheck
Scheduling	create reminder	Có	Future time + persistent job

HUMAN-IN-THE-LOOP

Interrupt là trạng thái bền vững, không phải popup giả lập.

01

Phát interrupt.

02

status interrupted.

03

Draft + actions.

PERSISTENT THREAD

Checkpoint Postgres giữ mạch hội thoại và interrupt **qua restart.**

- ✓ Internal ID ghép user và public thread ID.
- ✓ Không dùng chung state giữa hai user.
- ✓ Hết hạn xóa metadata và checkpoint.
- ✓ Resume kiểm tra thread và owner.

DATA BOUNDARY

Mọi dữ liệu cá nhân đều được lọc theo owner đã xác thực.

Threads

owner_id + thread_id.

Tasks

owner_id khi list/update/delete.

Memory

owner, expiry, source validity.

Calendar

OAuth credential riêng từng user.

CONSENT MODEL

AI chỉ nhận một *authorized message view*, không nhận raw chat tùy ý.

Server dựng view từ participant còn hiệu lực, quyền AI, contribution consent và cửa sổ thời gian.

PROVENANCE

Khi consent thay đổi, candidate cũ không còn mặc nhiên hợp lệ.

01

Generate

Lưu source + hash.

02

Consent changes

Hash đổi.

03

User accepts

Server re-check.

PROMPT INJECTION

Conversation text được coi là dữ liệu không tin cậy.

- ✓ Normalize Unicode và bắt obfuscation.
- ✓ Ẩn dòng có dấu hiệu injection.
- ✓ Escape < > trước delimiter.
- ✓ Cắt context tại 100.000 ký tự.
- ✓ Prompt cấm làm theo instruction trong data.

INPUT GUARDRAIL

Hard safety chạy trước LLM planner.

Injection

Ghi đè rule, tiết lộ prompt, jailbreak.

Sensitive harm

Tội phạm, tự hại, vũ khí, abuse và nhóm rủi ro.

Hard safety không phụ thuộc model; request bị chặn không tới planner hoặc tool.

SEMANTIC GATE

Không đủ chắc chắn thì **hỏi lại trước khi hành động.**

Lớp phân loại định hướng ba quyết định rõ ràng: cho phép, yêu cầu làm rõ hoặc từ chối.

DEFENSE IN DEPTH

Nội dung hành động được kiểm tra cả trước và sau khi user chỉnh draft.

01

Planner draft

Tạo đề xuất.

02

Policy check

Chặn mục tiêu xấu.

03

User edits

Sửa draft.

OUTPUT GUARDRAIL

Plain LLM output được quét secret và dấu hiệu lộ prompt.

Pattern gồm database URL, API keys, JWT-like token, password assignment và private key.

AUTH & ABUSE CONTROL

JWT, validation và rate limit bảo vệ đường vào.

JWT auth

Route cá nhân yêu cầu current user.

Schema bounds

Message 5k; context item 10k; history 200.

Chat rate

Mặc định 15 request/phút.

CRUD rate

Mặc định 60 request/phút.

COST CONTROL

Usage được ghi best-effort; chat mới bị chặn khi **chạm budget.**

- ✓ Ghi provider, model, tokens và cost.
- ✓ Lỗi logging không làm hỏng turn.
- ✓ Admin nhận cảnh báo realtime.
- ✓ Resume confirmation không bị chặn giữa chừng.

MODEL PORTABILITY

Một factory hỗ trợ Google, Groq và OpenAI.

Google

ChatGoogleGenerativeAI
Mặc định gemini-2.5-flash

Groq

ChatGroq
GROQ_API_KEY

Đổi model vẫn phải chạy lại acceptance eval; portability không đồng nghĩa chất lượng tương đương.

REALTIME

WebSocket làm task, lịch và reminder phản ánh ngay trên UI.

Task events

created, updated, deleted, suggested.

Calendar events

created, updated, deleted từ app hoặc polling.

Broadcast theo user ID giúp đồng bộ nhiều tab/thiết bị của cùng tài khoản.

CALENDAR SYNC

Thay đổi từ Google được bắt bằng **incremental sync token**.

- ✓ Polling mặc định mỗi 20 giây.
- ✓ Chỉ poll user online đã nối Calendar.
- ✓ HTTP 410 chạy full resync.
- ✓ Lỗi một user không dừng tick.

DEGRADED MODE

Lỗi khởi tạo agent không kéo sập **toàn bộ Core API.**

Lifecycle bắt lỗi checkpointer, đánh dấu personal_agent unavailable và tiếp tục phục vụ phần lỗi.

PERSISTENCE BOUNDARIES

Ba loại trạng thái có ba cơ chế lưu bền vững.

TRẠNG THÁI	CƠ CHẾ	SỐNG QUA RESTART?
Dữ liệu ứng dụng	PostgreSQL + SQLAlchemy	Có
Agent thread / interrupt	LangGraph Postgres checkpointer	Có
Reminder jobs	APScheduler SQLAlchemyJobStore	Có
WebSocket connections	Process memory	Không; client reconnect

DEPLOYMENT PROFILE

Một worker sở hữu rõ **realtime, scheduler và burst control.**

Cấu hình này phù hợp cho MVP/demo: ít điểm phối hợp, dễ quan sát và giữ thứ tự side effect nhất quán.

TEST STRATEGY

Bảng chứng được chia thành unit, integration và real-LLM acceptance.

Deterministic tests

Guardrail, schema, routing, service rules.

Integration tests

API, auth, consent, DB, scheduler, WebSocket.

SAFETY COVERAGE

Guardrail tests bao phủ request, context, action và output.

Request

Injection, harm, domain, follow-up.

Context

Chat chứa harm hoặc injection.

Action

Draft nguy hiểm bị chặn trước interrupt.

Output

Secret và prompt leakage bị thay thế.

HITL EVIDENCE

Test đi xuyên suốt interrupt → resume → side effect.

Graph test chứng minh invoke đầu trả interrupt và chỉ sau approved resume mới tạo event.

CURRENT AUTOMATED SUITE

Bộ test hiện tại được chạy lại trên **chính nhánh này.**

Full backend suite hoàn tất ngày 24/08/2026 trong 6 phút 10 giây và không ghi nhận lỗi kiểm thử.

Unit

API

Agent graph

Guardrail

Persistence

Đây là bằng chứng hồi quy trực tiếp trên code hiện tại; một test tích hợp tùy chọn được skip theo môi trường.

RELEASE QUALITY BAR

Một quality bar tham vọng nhưng khả thi cho release candidate.

 $\geq 85\%$

mục tiêu case pass rate end-to-end

 $\geq 95\%$

mục tiêu tool routing accuracy

100%

mục tiêu memory isolation

 $\leq 5s$

mục tiêu latency p50

Các con số này là KPI mục tiêu cho lần real-LLM acceptance kế tiếp: đủ cao để phản ánh chất lượng sản phẩm, đồng thời có thể đo lặp lại trên dataset, model và PostgreSQL cô lập.

QUALITY LEVERS

Ba đòn bẩy đưa chất lượng lên đúng quality bar.

**Contract-first routing**

Tool description rõ intent; schema bắt buộc đối tượng, thời gian và scope; trace lại quyết định planner theo từng case.

**Grounded memory**

Lọc owner trước retrieval; áp dụng type, confidence, expiry và provenance trước khi đưa memory vào context.

PRODUCTION HARDENING

Bốn lớp hardening đưa nền tảng từ demo tới release candidate.

Semantic decisions

Chuẩn hóa allow / clarify / deny và khóa bằng integration test.

Unified output safety

Mọi terminal response đi qua cùng secret và leakage validation.

Evidence-aware UI

Hiển thị đúng nguồn thực sự đã dùng trong từng turn.

Scale coordination

Externalize realtime, scheduler leadership và distributed limit khi scale.

RELEASE PLAN • P0

Ba bước tạo một release candidate có thể đo và tái lập.

STEP 01

Lock behavior

Đóng semantic decision và output validation bằng test tích hợp xác định.

STEP 02

Run full acceptance

Chạy đủ dataset trên model, prompt, database và cấu hình được version hóa.

RELEASE PLAN • P1

Nâng routing, memory và latency bằng eval-driven development.

OBSERVE	Thu case fail thật, giữ prompt/model/version	dataset
DIAGNOSE	Phân loại planner, tool, retrieval hay UI	trace
FIX	Sửa rule/schema/tool contract nhỏ nhất	code
REGRESS	Unit + integration + full real-LLM eval	gate
PROMOTE	Chỉ đổi status khi mọi threshold đạt	release

PRODUCTION GATE

Release candidate được quyết định bằng sáu tiêu chí định lượng.

TIÊU CHÍ	ĐÍCH RC ĐỀ XUẤT	BẰNG CHỨNG BẮT BUỘC
Case pass rate	≥ 85%	Full real-LLM dataset
Tool routing	≥ 95%	Trace tool call theo intent
Memory isolation	100%	Cross-user negative tests
Pre-confirm side effect	0%	Interrupt/resume integration
Forbidden claim rate	0%	Output safety cases
Latency p50	≤ 5 giây	End-to-end telemetry

Lộ trình nâng cấp đi từ chất lượng hành vi đến khả năng scale.

NOW**Release evidence**

- ✓ Unified safety path
- ✓ Versioned full eval
- ✓ Dashboard sáu release gates

NEXT**Experience quality**

- ✓ Routing $\geq 95\%$
- ✓ Memory isolation 100%
- ✓ Latency p50 $\leq 5s$

WHAT IS ALREADY REAL

Orbit đã có một nền tảng agentic end-to-end được hiện thực hóa.

- ✓ LLM planner được bind với 14 tool nghiệp vụ.
- ✓ Interrupt/resume kiểm soát side effect lịch và reminder.
- ✓ Thread, scheduled job và dữ liệu sống qua restart.
- ✓ Consent, provenance và owner checks được thực thi ở server.

FINAL TRUTH

//
AI hành động hữu ích — và vẫn biết dừng đúng lúc.

Hiểu bối cảnh, dùng công cụ, xin xác nhận và để người dùng giữ quyền kiểm soát.